




AI-ASSISTED FRAUD DETECTION

E-commerce & Payment Platform Intelligence

Fraud Detection Case Study: Dengesiz Verilerde Karar Verme

Bir dijital ödeme ve e-ticaret platformu, günlük milyonlarca işlemi gerçek zamanlı olarak işlemektedir. Platformun temel hedeflerinden biri, dolandırıcılık (fraud) kaynaklı finansal kayıpları minimum seviyede tutarken, gerçek kullanıcıların işlemlerini gereksiz yere engellememektir.

Şirket, geçmiş işlem verilerini kullanarak bir **fraud detection (ikili sınıflandırma)** sistemi geliştirmiştir. Mevcut veri seti yaklaşık **1.8 milyon işlem**den oluşmaktadır ve işlemlerin yalnızca **%1.4'ü dolandırıcılık** olarak etiketlenmiştir. Bu durum, problemin ciddi derecede dengesiz (imbalanced) bir yapıya sahip olduğunu göstermektedir.

Modelleme sürecinde üç farklı yaklaşım değerlendirilmiştir:

- **Logistic Regression**, hızlı ve düşük gecikmeli bir temel model olarak,
- **XGBoost**, daha karmaşık örüntüleri yakalayabilen güçlü bir ağaç tabanlı model olarak,
- **Zero-shot LLM tabanlı sınıflandırıcı**, etiketli veri ihtiyacı olmadan karar verebilen esnek bir yaklaşım olarak.

Doğrulama sonuçları incelendiğinde, Logistic Regression modelinin yüksek precision değerine rağmen düşük recall sergilediği, yani birçok dolandırıcılık vakasını kaçırdığı görülmektedir. XGBoost modeli daha dengeli bir precision-recall profili sunarken, zero-shot LLM yaklaşımı nispeten daha düşük doğrulukla birlikte **etiketleme maliyetini ortadan kaldırma ve hızlı adaptasyon** avantajı sağlamaktadır.

İş birimleri açısından **false negative'ler (dolandırıcılığı kaçırmak)** doğrudan finansal kayba yol açtığı için son derece maliyetlidir. Öte yandan, yanlış pozitifler manuel inceleme yükünü artırmakta ve operasyonel kapasiteyi zorlamaktadır. Buna ek olarak, sistemin **250 ms altında yanıt verme** zorunluluğu bulunmaktadır; aksi takdirde ödeme deneyimi olumsuz etkilenmektedir.

Amaç

Bu case study'nin amacı, bir **fraud detection (dolandırıcılık tespiti)** problemi için:

- Klasik ML modellerinin sonuçlarını
- Zero-shot **Large Language Model (LLM)** yaklaşımlarıyla
- **farklı LLM sağlayıcıları üzerinden**

karşılaştırmalı olarak değerlendirmektir.

Kullanılacak LLM'ler

Katılımcılar aşağıdaki modelleri **ayrı ayrı** çalıştıracaktır:

- **GPT** (OpenAI)
- **Gemini** (Google)
- **Cohere Command**

! Aynı prompt ve context her modelde korunacaktır.

Katılımcılardan beklenen:

“Hangi model daha iyi cevap verdi?” değil,

“Hangi LLM bu bağlamda daha güvenilir bir karar destek aracı?” sorusuna cevap vermeleridir.

Ayrıca ekip, yalnızca metriklere bakarak değil;

iş hedefleri, operasyonel kısıtlar ve sürdürülebilirlik açısından hangi yaklaşımın **production ortamı için en uygun** olduğunu belirlemek zorundadır.

CONTEXT_JSON

```
{
  "task": "fraud detection (binary classification)",
  "dataset_size": 1800000,
  "fraud_rate": 0.014,
  "models": ["logistic_regression", "xgboost", "zero_shot_llm_classifier"],
  "validation": {
    "logistic_regression": {"precision": 0.81, "recall": 0.22},
    "xgboost": {"precision": 0.74, "recall": 0.61},
    "zero_shot_llm_classifier": {"precision": 0.66, "recall": 0.58}
  },
  "constraints": {
    "false_negatives_costly": true,
    "manual_review_capacity_limited": true,
    "latency_ms_max": 250
  }
}
```

GÖREV 1 – Metriklerin Teknik Yorumu

Yapılacak İş

Aşağıdaki soruya **kısa ve teknik** bir paragraf yazınız:

Aşağıdaki soruya yazılı cevap veriniz:

Fraud detection probleminde precision ve recall metrikleri neden kritik öneme sahiptir?
Bu metriklerin iş maliyetiyle ilişkisini açıklayınız.

GÖREV 2 – USER PROMPT TASARIMI

Yapılacak İş

Katılımcıdan beklenen:

- Aşağıdaki hedefleri sağlayan **kendi USER PROMPT’unu yazması**
- Bu prompt tüm LLM’lerde **aynen** kullanılacaktır

Prompt hedefleri:

- Production kararı istemeli
- Metriklerin yanında iş kısıtlarını dikkate almalı
- Varsayım ve uydurma bilgiyi engellemeli

✂ Örnek (zorunlu değil):

“Aşağıdaki fraud detection context’ine göre, üretim ortamı için en uygun yaklaşımı değerlendir.”

GÖREV 3 – Temperature Deneyi

Yapılacak İş

Katılımcı, Streamlit veya Python kodu kullanarak her bir LLM için **aynı context + aynı user prompt** ile:

- Temperature = **0.0**
- Temperature = **0.7**

olacak şekilde **iki ayrı çıktı üretmelidir**.

Cevaplanacak Soru

Temperature değişimi, modelin:

- karar dili,
- risk vurgusu,
- ve spekülasyon eğilimi

üzerinde nasıl bir etki yaratmıştır?

GÖREV 4 – Nihai Production Kararı

Yapılacak İş

Katılımcı, **temperature = 0.2** ile tek bir final çıktı üretmeli ve aşağıdaki formatta cevap vermelidir:

Katılımcı, **her bir LLM için ayrı bir final karar** üretmelidir. (referans temperature aralığı belirtmelidir)

Çıktı Formatı (Her model için)

Model:

(GPT / Gemini / Cohere)

Recommendation:

(seçilen yaklaşım)

Reasoning:

- Madde 1
- Madde 2

Risks:

- Risk 1
- Risk 2

Next actions:

- Aksiyon 1
- Aksiyon 2